



MASTER IN BUSINESS INTELLIGENCE & BIG DATA ANALYTICS FOR BUSINESS - A.A. 2025/2026

Benchmark della produzione scientifica di UniBG e confronto con atenei comparabili

Homework 1 - Scraping e ETL

Francesco Peraro



github.com/fperaro/AIDA-for-Business---HW1

Indice

1. Scenario, obiettivo e utilità dell'analisi
2. Stakeholders
3. Domande di analisi
4. Atenei del confronto
5. Fonti dati
6. Architettura tecnica
7. Tecnologie utilizzate
8. Caratteristiche dei dataset
9. Problemi di data quality rilevati
10. Metodi di trattamento adottati
11. Schema del Data Warehouse
12. Contenuto del Data Warehouse
13. Criticità emerse e limiti metodologici
14. Obiettivi raggiunti e prossimi passi

Obiettivo e utilità dell'analisi

Obiettivo

- Contesto: monitoraggio della produzione scientifica dell'Università degli Studi di Bergamo, a supporto del reporting istituzionale
- Obiettivo di questo homework è quello di costruire una catena di elaborazione dati completa (fonti eterogenee -> preparazione -> Data Warehouse) a per poter confrontare UniBG e un gruppo di atenei comparabili
- Su questa pipeline si potrà poggiare l'analisi strategica e la creazione di dashboard e rappresentazioni grafiche degli insights

Utilità

- Fornisce alla governance un riferimento comparativo esterno, oggi assente: UniBG dispone di dati completi su sé stessa (repository istituzionale Aisberg) ma nessun confronto sistematico con atenei di profilo simile
- Rende visibili distorsioni che un confronto in termini assoluti nasconde: effetto dimensione, presenza di un'area medica, differenze di copertura tra fonti
- Rilevazione di osservazioni collaterali: e.g. il 96,6% degli articoli di Bergamo ha un DOI reale ma solo l'8% lo ha catalogato in Aisberg - è una procedura interna da correggere

Stakeholders

Ruolo	Interesse rispetto all'analisi
Rettore e Direzione Generale	Posizionamento dell'Ateneo, supporto a decisioni strategiche e comunicazione istituzionale
Prorettore alla Ricerca	Monitoraggio della produzione scientifica, individuazione di aree da rafforzare
Referenti ricerca dei dipartimenti	Confronto a livello di area disciplinare, lettura dei dati specifici del proprio dipartimento (Aisberg)

Domande di analisi

- Le seguenti domande hanno guidato le scelte di schema del Data Warehouse - le risposte sono oggetto dell'Homework 2:
 - Come si distribuisce la produzione scientifica per area disciplinare tra gli atenei del confronto?
 - Come è cambiata la produzione nel periodo 2015-2025?
 - Qual è il tasso di accesso aperto (open access) e come varia tra atenei?
 - Come cambia il confronto normalizzando per personale docente/ricercatore, PTA, iscritti e laureati?
 - Come si colloca UniBG all'interno di un cluster di atenei simili, in termini di quantità e qualità della ricerca?
- Ulteriori domande potranno emergere in fase di analisi, sulla base dello schema già disponibile

Atenei del confronto

Ateneo	Iscritti (2024/25)	Docenti/ric. (2024)	Note
Bergamo	18.954	507	Nessuna area medica
Brescia	16.456	643	
Pavia	26.515	1.049	Ateneo di dimensione superiore al gruppo
Ferrara	27.101	717	
Modena e Reggio Emilia	25.851	972	
Trieste	17.534	711	
Ca' Foscari Venezia	18.941	689	Nessuna area medica/STEM

Criterio di selezione: dimensione (~15-27k iscritti) e offerta multidisciplinare, con esclusione di atenei fuori scala o monodisciplinari.
Fonte dati: USTAT MUR


Fonti dati

Fonte	Metodo di acquisizione	Contenuto
OpenAlex	API pubblica	Pubblicazioni bibliometriche per istituzione (benchmark esterno)
Aisberg (UniBG)	Estrazione interna (dump tabelle CINECA/IRIS)	Pubblicazioni complete UniBG, dettaglio autori/dipartimenti
AlmaLaurea	Scraping (pagine HTML statiche)	Laureati per ateneo, dato di normalizzazione
USTAT MUR	Estrazione open data (CSV)	Personale docente/ricercatore, PTA, iscritti, serie 2015-2024

Nota metodologica: l'estrazione interna per Aisberg riflette il ruolo di analista dello Staff di Ateneo con accesso privilegiato; per le altre fonti si è adottata la prospettiva di un analista esterno senza accesso privilegiato.

Non ho usato Scopus o Web of Science come fonte di confronto: sono ad accesso autenticato e i loro termini di servizio vietano l'estrazione sistematica anche con credenziali istituzionali, con il rischio concreto di far sospendere l'accesso a tutto l'Ateneo. OpenAlex è pubblico e non comporta questo rischio.

Architettura tecnica



Source layer: dump raw da ciascuna fonte, nessuna elaborazione

Staging: parsing, deduplicazione, tabelle ponte, nessuna aggregazione

Data Warehouse: schema a stella predisposto all'analisi

Perché tre layer separate? Ogni trasformazione resta tracciabile fino al dato grezzo originale; questo fa sì che un problema scoperto in staging o nel DW non richieda di rifare l'estrazione da capo

Tecnologie utilizzate

- Acquisizione dati: Python, con la libreria requests per le chiamate alle API e BeautifulSoup per leggere le pagine web nello scraping
- Preparazione dei dati in staging: Python/pandas; esempi di intervento: scomposizione della stringa dipartimento in nome e periodo di validità, e l'unione di tre indicatori di personale (docenti, personale tecnico-amministrativo, iscritti) in un'unica serie storica per ateneo e anno
- Data Warehouse: SQLite, sufficiente per il volume di dati in gioco, con i controlli di integrità tra le tabelle attivi
- Non sono stati usati Hadoop o Spark: il volume di dati non giustifica la complessità aggiuntiva di strumenti tipici di analisi Big Data
- Lo strumento di visualizzazione sarà scelto nell'Homework 2, in base ai requisiti della consegna

Dataset Aisberg: caratteristiche

- 43.064 prodotti scientifici (coppie pubblicazione-autore), 33.629 pubblicazioni uniche
- Periodo coperto: 1990-2025
- 65 tipologie di prodotto distinte (articoli, capitoli, atti di convegno, monografie, ecc.)
- Campi disponibili: titolo, anno, tipologia, DOI, ISSN/ISBN, autori, dipartimento con storicizzazione, tipo di accesso open
- Colonna 'Codice fiscale' presente nel dump originale: esclusa in fase di staging, dato personale sensibile

Dataset OpenAlex: caratteristiche

- Raccolta completata per i 7 atenei, periodo 2015-2025, scorrendo i risultati pagina per pagina - 184.887 record totali
- Bergamo 9.368, Brescia 26.641, Pavia 43.592, Ferrara 26.416, Modena e Reggio Emilia 31.947, Trieste 28.224, Ca' Foscari 18.699
- Copertura di OpenAlex verificata su Bergamo (l'unico ateneo per cui ho un dato interno completo con cui confrontare): 47% aggregato, ma molto diseguale per tipologia - 83,6% sugli articoli su rivista, 29,6% sui capitoli, 0,5% sugli atti di convegno
- Il confronto tra i 7 atenei è quindi più attendibile se limitato ad articoli e review, dove la copertura è maggiore

Dataset di normalizzazione

- USTAT MUR: personale docente/ricercatore, personale tecnico-amministrativo, iscritti - serie 2015-2024 per tutti i 7 atenei
- AlmaLaurea: laureati per ateneo, anno di riferimento 2025, verificato omogeneo su tutti i 7 atenei
- Utilizzo: normalizzare il confronto sulla produzione scientifica per dimensione dell'ateneo (pubblicazioni/docente, pubblicazioni/laureato)
- Per i docenti ho considerato la definizione più “ristretta”: professori di ruolo e ricercatori; quella più estesa, che aggiunge assegnisti di ricerca e docenti a contratto, risente più facilmente di variazioni amministrative non legate alla produttività scientifica

Problemi di data quality rilevati

Problema	Fonte	Descrizione
Dato personale sensibile	Aisberg	Colonna codice fiscale presente nel dump grezzo
Denormalizzazione	Aisberg	Una riga per coppia pubblicazione-autore, non per pubblicazione
Dipartimento non storicizzato	Aisberg	Riorganizzazioni di ateneo non tracciate in un campo strutturato
Data sentinella	Aisberg	"01/01/1900" usata come placeholder per data di inizio non nota
DOI non catalogato	Aisberg	96,9% dei record senza DOI in Aisberg; verificato che il 96,6% degli articoli ha comunque un DOI reale (via OpenAlex) - lacuna di catalogazione, non assenza del dato
Titoli duplicati	Aisberg	580 titoli con handle diverso: 381 spiegabili come ciclo working paper -> pubblicato (legittimo), 199 da titolo identico e stessa tipologia (in parte falsi positivi da titoli generici)
Copertura diseguale per tipologia	OpenAlex	47% aggregato su Bergamo, ma 84% sugli articoli e 0,5% sugli atti di convegno - non e' un problema uniforme
Ambiguità nome istituzione	USTAT MUR	Nomi simili riferiti a enti diversi (es. IUSS Pavia, SISSA Trieste, IUAV Venezia)

Fonte: elaborazione propria su estrazione interna Aisberg, raccolta dati OpenAlex e open data USTAT MUR.

Metodi di trattamento adottati

- Esclusione permanente della colonna codice fiscale in fase di staging
- Ogni pubblicazione compariva una volta per ogni co-autore (43.064 righe); per ottenere una riga per pubblicazione (33.629) ho tenuto i dati della pubblicazione una sola volta, spostando tutti i co-autori - nessuno escluso - in una tabella separata dedicata
- Parsing della stringa dipartimento in nome, data di inizio, data di fine
- Trattamento della data sentinella "01/01/1900" come valore mancante, non come data reale
- Filtro del periodo Aisberg a 2015-2025 nel caricamento nel Data Warehouse: il dump copre 1990-2025, ma includerlo per intero avrebbe generato righe collegate ad anni assenti dalla tabella Dim_Anno
- Registrazione delle anomalie in una tabella separata, senza eliminazione massiva
- Disambiguazione dei nomi istituzione su USTAT MUR

Schema del Data Warehouse



Riquadri azzurro chiaro = tabelle fact. Bianco = dimensioni. Grigio chiaro = tabella ponte (bridge)
Due Fact_Pubblicazione separate perché OpenAlex e Aisberg usano tassonomie di tipologia diverse (65 vs 15 categorie): mapparle 1:1 sarebbe arbitrario.

Contenuto del Data Warehouse

Tabella	Cosa contiene ciascuna riga
Dim_Ateneo	Uno dei 7 atenei: nome, anno di fondazione, numero di laureati nel 2025
Dim_Anno	Un anno, da 2015 a 2025
Dim_Tipo_Pubblicazione	Un tipo di pubblicazione secondo OpenAlex (articolo, capitolo, atti di convegno...), con l'indicazione se l'indicizzazione è affidabile per quel tipo
Dim_Area_Disciplinare	Una combinazione di ambito, campo e sotto-campo disciplinare, secondo la classificazione OpenAlex
Dim_Dipartimento	Un dipartimento dell'Università di Bergamo, con il periodo in cui è stato attivo
Fact_Pubblicazione_OpenAlex	Una pubblicazione, su uno qualsiasi dei 7 atenei: titolo, anno, tipo, area disciplinare, se è ad accesso aperto
Fact_Pubblicazione_Aisberg	Una pubblicazione, solo dell'Università di Bergamo: stesse informazioni di sopra, più dettagliate (DOI, ISSN/ISBN, identificativi Scopus/WoS)
Bridge_Pubblicazione_Autore	Un autore di una pubblicazione di Bergamo: nome, dipartimento di appartenenza al momento della pubblicazione
Fact_Personale_Ateneo	Un ateneo in un dato anno: numero di docenti/ricercatori, personale tecnico-amministrativo, iscritti

Criticità emerse e limiti metodologici

Limiti metodologici

- Il confronto sui totali aggregati è distorto dalla presenza/assenza dell'area medica (assente a Bergamo e Ca' Foscari)
- La copertura OpenAlex varia molto per tipologia (84% articoli, 30% capitoli, 0,5% atti di convegno su Bergamo); il confronto a 7 atenei è più solido se limitato ad articoli e review
- Ca' Foscari mostra quasi il doppio delle pubblicazioni OpenAlex di Bergamo pur con dimensione comparabile: ipotesi non verificata è che il mix disciplinare (Bergamo ha ingegneria, con una produzione orientata agli atti di convegno; Ca' Foscari no) renda Ca' Foscari più visibile a OpenAlex, non necessariamente più produttiva

Errori tecnici incontrati e corretti in corso d'opera

- Script di raccolta dati: rilanciarlo dopo un'interruzione sovrascriveva i dati di atenei già completati - corretto distinguendo "non ancora iniziato" da "già completato"
- Gestione iniziale dei limiti di richieste imposti dall'API insufficiente (veniva gestito solo il blocco isolato, non un rallentamento prolungato) - corretta con un tempo di attesa crescente e un punto di ripristino da cui riprendere senza rifare tutto da capo
- Requisito di autenticazione API OpenAlex cambiato rispetto alla documentazione nota - individuato e corretto in corso d'opera tramite registrazione e API-Key

Obiettivi raggiunti e prossimi passi

Raggiunto	Non raggiunto / parziale
Identificazione e acquisizione di 4 fonti dati eterogenee (API, scraping, estrazione interna, open data)	Verifica della copertura OpenAlex limitata al solo ateneo per cui si dispone di un dato interno completo di confronto (Bergamo)
Staging completo del dataset Aisberg, con gestione esplicita del dato sensibile	Ipotesi sul mix disciplinare (es. Ca' Foscari vs Bergamo) formulata ma non verificata con dati strutturati sugli altri atenei
Normalizzazione per dimensione (docenti, PTA, iscritti, laureati) su tutti i 7 atenei	
Raccolta dati OpenAlex completata: 184.887 pubblicazioni sui 7 atenei	
Data Warehouse creato e popolato, con controllo di integrità referenziale attivo	

Prossimi passi: analisi e visualizzazione dei dati, oggetto dell'Homework 2, a partire dal Data Warehouse già pronto.